

# EAI

## Lab 3

## Report


系級	113 電機乙
學號	F64096114
姓名	郭家佑

- 說明不同 tuning 方式的原理及如何實作

1. standardization

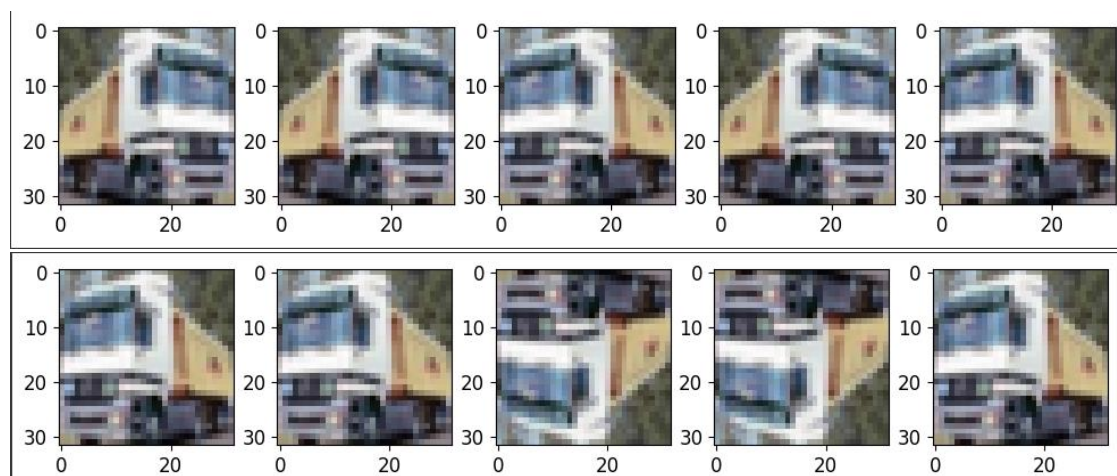
先算出平均與標準差，在利用 transform 套件裡的

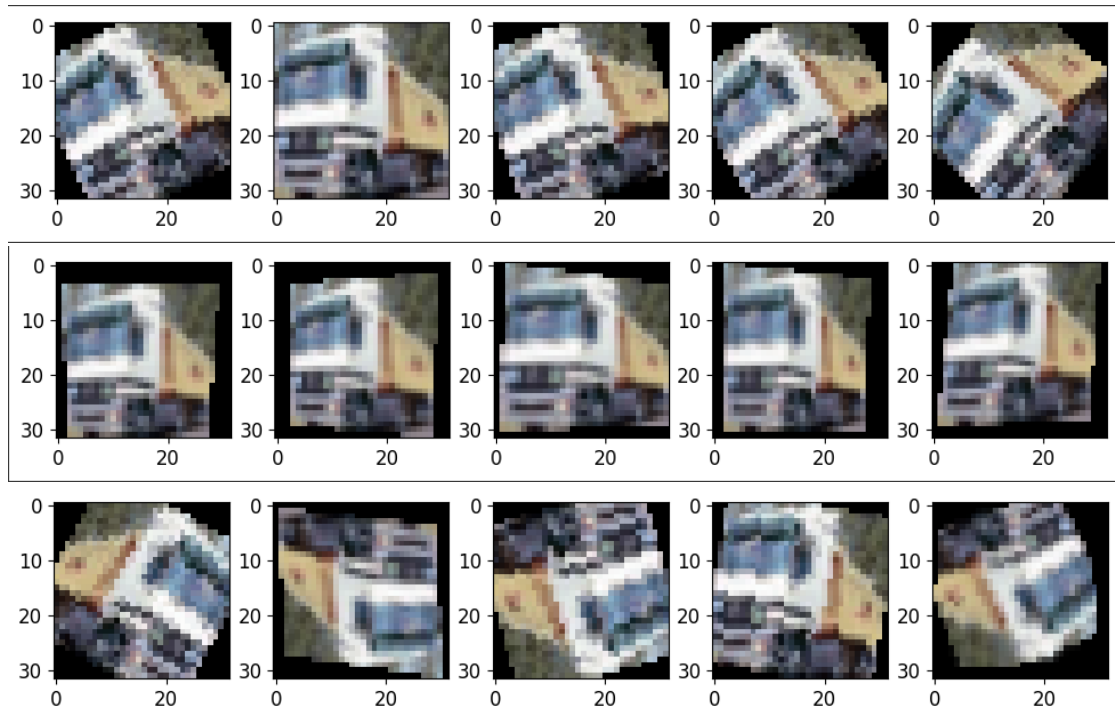
Normalize 來標準化。



2. Data augmentation

使用水平、垂直、旋轉、翻轉來增加訓練資料量。






### 3. Dynamic LR rate

利用類似 exp\_range Cyclical Learning Rates 來動態調整學習率。

```
[11] # learning rate shedule
def adjust_learning_rate(optimizer, epoch):
    # define your lr scheduler
    if epoch % 2 == 0:
        optimizer.param_groups[0]['lr'] += optimizer.param_groups[0]['lr']*0.2
    else:
        optimizer.param_groups[0]['lr'] -= optimizer.param_groups[0]['lr']*0.2
    # for param_group in optim.param_groups:
    #     param_group['lr'] = lr
```



### 4. Different batch size

將原先 128 的 batch\_size 變大，訓練時間減少許多。

- 說明並比較不同 tuning 方式如何造成影響

1. Standardization

使資料靠平均集中，可使 back propagation 時不會受到 gradient vanishing 影響。

2. Data augmentation

增加訓練集資料可使在少的資料集中也可以有好的訓練結果

3. Dynamic LR rate

有動態調整 LR 皆會比 static LR 好很多。

```
Epoch: 55  
learning rate: 0.0006227655267306558  
Train loss: 0.154 | Train acc: 0.948  
Val loss: 0.416 | Val acc: 0.866  
Test loss: 0.317 | Test acc: 0.899
```

自製 dynamic LR

```
Epoch: 55  
learning rate: 0.0015625  
Train loss: 0.143 | Train acc: 0.951  
Val loss: 0.401 | Val acc: 0.873  
Test loss: 0.317 | Test acc: 0.903
```

StepLR

```
Epoch: 55  
learning rate: 0.05  
Train loss: 0.499 | Train acc: 0.827  
Val loss: 0.750 | Val acc: 0.752  
Test loss: 0.556 | Test acc: 0.812
```

Static LR

4. Different batch size

較大的 batch size 雖然訓練時間快很多，但是準確率沒辦法跟小的 batch\_size 同水平。

```
Epoch: 55  
learning rate: 0.0015625  
Train loss: 0.254 | Train acc: 0.911  
Val loss: 0.496 | Val acc: 0.833  
Test loss: 0.420 | Test acc: 0.864
```

大 batch\_size


```
Epoch: 55  
learning rate: 0.0015625  
Train loss: 0.143 | Train acc: 0.951  
Val loss: 0.401 | Val acc: 0.873  
Test loss: 0.317 | Test acc: 0.903
```


小 batch\_size

- 截圖並說明各項結果

由 Accuracy 的圖形結果可看出有了 Dynamic learning rate 的幫助下能帶來顯著的改善，尤其是再改動後的那次，都能使原本已經快要飽和的準確率又跳高了一截，幫助整體預測的準度，最終測試達 90%。

```
Epoch: 55  
learning rate: 0.0015625  
Train loss: 0.143 | Train acc: 0.951  
Val loss: 0.401 | Val acc: 0.873
```






Test loss: 0.317 | Test acc: 0.903


- 如何搭建 Resnet18

首先是搭建 block 網路，其內部由兩個 Convolution 和兩個 batch normalization 和一個 ReLU 層所組成，最後一層要與 input 做 shortcut 的動作再 ReLU 輸出。



接著利用先前搭建的 block 網路來建 ResNet18，透過

make\_layer 來串接所建立的子 layer，由於每大層都要有兩個 block，因此 num\_blocks=2，而剩下的參數就對照 ResNet18 各自填入對應的值，最後再利用這五大層加上頭尾的 convolution 和 fully-connected 就建立完成。



- 實作過程中遇到的困難及你後來是如何解決的

一開始其實不太懂 LR 要如何動態調整，經過搜尋後大約有了想法，又發現助教有在 code 裡面幫我們加上一般的遞減 LR 了，因此就模仿他寫出來。此外，原先對於 ResNet 的 short cut 路徑為何就能讓網路一直加深而能繼續收斂有點好奇，後來經過論文公式的推導與作者本人在 YT 的解說後就清楚了。